

# FET445 Veri Madenciliği

**UÇUŞ GECİKME TAHMİNİ**

**GRUP: TURBULENCE**

**Youtube link:**

**<https://www.youtube.com/watch?v=obqgXc4Q7BA>**

# UÇUŞ GECİKME TAHMİNİ

## Problemin Açıklaması:

Havacılık sektöründe rötarlar, hem operasyonel maliyetleri artırıyor hem de yolcu memnuniyetini düşürüyor. Bizim amacımız; uçuş gerçekleşmeden önce, mevcut verileri sınıflandırma yöntemiyle uçağın rötar yapıp yapmayacağı önceden tahmin etmek.



# Veri Seti Açıklaması:

**Linki:** <https://www.kaggle.com/datasets/usdot/flight-delays>

Veri Seti: ABD Ulaştırma Bakanlığı'na ait (US DOT) gerçek "Airline On-Time Performance" veri setini kullandık.

**Yapı:** Üç tablo flights.csv, airlines.csv, airports.csv birleştirilerek kullanılmıştır.

**Boyut:** 5.8 milyon satır ve 40 sütun.

Flights tablosunun boyutu : (5819079, 31)  
Airports tablosunun boyutu : (322, 7)  
Airlines tablosunun boyutu : (14, 2)

# Size, özellik tipi


```
[1]: 1 df_flights.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 5819079 entries, 0 to 5819078
Data columns (total 31 columns):
 #   Column           Dtype  
 --- 
 0   YEAR            int64  
 1   MONTH           int64  
 2   DAY             int64  
 3   DAY_OF_WEEK     int64  
 4   AIRLINE          object 
 5   FLIGHT_NUMBER   int64  
 6   TAIL_NUMBER     object 
 7   ORIGIN_AIRPORT  object 
 8   DESTINATION_AIRPORT  object 
 9   SCHEDULED_DEPARTURE int64  
 10  DEPARTURE_TIME  float64 
 11  DEPARTURE_DELAY float64 
 12  TAXI_OUT         float64 
 13  WHEELS_OFF       float64 
 14  SCHEDULED_TIME  float64
```

```
15  ELAPSED_TIME      float64 
16  AIR_TIME          float64 
17  DISTANCE          int64  
18  WHEELS_ON          float64 
19  TAXI_IN            float64 
20  SCHEDULED_ARRIVAL int64  
21  ARRIVAL_TIME      float64 
22  ARRIVAL_DELAY     float64 
23  DIVERTED          int64  
24  CANCELLED         int64  
25  CANCELLATION_REASON object 
26  AIR_SYSTEM_DELAY   float64 
27  SECURITY_DELAY     float64 
28  AIRLINE_DELAY      float64 
29  LATE_AIRCRAFT_DELAY float64 
30  WEATHER_DELAY      float64
dtypes: float64(16), int64(10), object(5)
memory usage: 1.3+ GB
```

# Class Distribution (sınıflandırma ise)

**Sınıf Dağılımı:** Veri seti yüksek oranda dengesiz (imbalanced). Uçuşların çoğu zamanında kalkıyor, bu da modelin gecikmeleri öğrenmesini zorlaştırıyor.



# Temel Kullanılan Teknikler

## Zaman Segmentasyonu

Sürekli sayısal veriler, 5 farklı kategorik zaman dilimine (TIME\_OF\_DAY) dönüştürülmüştür. Bu işlem, modelin günün bölgümlerine göre gecikme örüntülerini daha iyi öğrenmesini sağlar

## Target Encoding:

Yüksek boyutlu değişkenler için ortalama gecikme oranı hesaplanarak sayısal bir değere dönüştürülmüştür. Bu sayede veri setinde yüzlerce yeni sütun olması engellenerek kategorik bilgi korunmuştur.

## One-Hot Encoding:

Düşük sınıf sayısına sahip olan değişkenler, modelin bu kategoriler arasındaki farkı net bir şekilde öğrenebilmesi için binary vektörlere dönüştürülmüştür

**Veri Entegrasyonu:** Kullanılan tablolar birleştirilerek havayolu ve havalimanı özellikleri analize dahil edilmiştir.

```
silinecek_sutunlar = [
    #sizintı yapanlar
    'DEPARTURE_TIME',
    'DEPARTURE_DELAY',
    'TAXI_OUT',
    'WHEELS_OFF',
    'ELAPSED_TIME',
    'AIR_TIME',
    'WHEELS_ON',
    'TAXI_IN',
    'ARRIVAL_TIME',
    'ARRIVAL_DELAY',
    #gereksizler hepsi aynı değer
    'YEAR',
    'COUNTRY_ORIGIN',
    'COUNTRY_DEST',
    #gürültüye sebebiyet verenler
    'TAIL_NUMBER',
    'FLIGHT_NUMBER',
    #gereksiz değişkenler
    'SCHEDULED_DEPARTURE',
    'SCHEDULED_HOUR',
    'SCHEDULED_ARRIVAL'
```

```
#eklenen zenginleştirmeler
'AIRLINE_NAME',
'AIRPORT_ORIGIN',
'CITY_ORIGIN',
'STATE_ORIGIN',
'LATITUDE_ORIGIN',
'LONGITUDE_ORIGIN',
'AIRPORT_DEST',
'CITY_DEST',
'STATE_DEST',
'LATITUDE_DEST',
'LONGITUDE_DEST',
```

# Train -test split oranı nedir?

Veri madenciliği sürecinde modelin başarısını tarafsız bir şekilde ölçebilmek için veri seti **Training** ve **Test** olmak üzere iki ana bölüme ayrılmıştır.

5.8 milyon satırlık büyük bir veri setiyle çalışıldığı için, modelin daha fazla veriyle öğrenmesini sağlamak ve yüksek varyans riskini azaltmak amacıyla **%80 Eğitim - %20 Test** stratejisi benimsenmiştir.

```
Flights tablosunun boyutu : (5819079, 31)
Airports tablosunun boyutu : (322, 7)
Airlines tablosunun boyutu : (14, 2)
Flights Train boyutu: (4655263, 31)
Flights Test boyutu: (1163816, 31)
```

```
Train Veri Boyutu: (4571137, 10)
Test Veri Boyutu: (1142871, 10)
```

# Performance metrikler nelerdir?

## Accuracy

Yapılan tahminlerden kaç tanesinin doğru olduğunu gösteren en temel metriktir

## ROC AUC

Geciken ve gecikmeyen sınıfların birbirinden ayırt etme yeteneğini ölçer

## F1 Score

Precision ve Recall değerlerinin harmonik ortalamasıdır

## PR AUC

Modelin gecikmeleri ne kadar kaliteli tahmin ettiğini doğrudan gösterir

# En İyi Model: RandomForestClassifier

**Geliştiren:** Zekeriya Deniz Uğurlu.

**Yaklaşım:** Bagging yöntemi kullanılarak çok sayıda karar ağacı ile aşırı öğrenme (overfitting) riski minimize edilmiştir.

**Hiperparametre Optimizasyonu:** RandomizedSearchCV yöntemi ve ROC-AUC optimizasyon metriği kullanılmıştır.



**Sınıf Dengesizliği Yönetimi:** Azınlık sınıfı (gecikmeler) olan "1" sınıfına 3 kat daha fazla ağırlık verilerek (`class_weight: {0:1, 1:3}`) modelin gecikmeleri yakalama hassasiyeti artırılmıştır.

**Özellik Seti:** PCA ve RFE gibi yöntemlerle gürültüden arındırılmış veri setleri üzerinde test edilmiştir.

# Modellerin Karşılaştırıldığı Tablo

Grup üyelerinin en iyi ana modelleri:

Üye	Model	accuracy	F1 Score	precision	recall	ROC AUC	PR AUC	MAE
Emine Güneş	Gradient Boosting Classifier +CA	82.27	0.05	0.61	0.03	67.85	32.40	27.46
Zekeriya Deniz Uğurlu	RandomFore stClassifier	81.70	0.41	0.48	0.35	74.78	43.56	18.30
Muhammed Mert Oruç	QDA+ANO VA F	79.12	0.14	0.26	0.09	61.49	24.35	20.89
Oğuzhan Özdemir	Extra Tree Classifier+ Selection	81.24	0.25	0.0015	0.75	68.08	31.85	18.01
Muhammet Enes İnal	Stacking + SelectFromM odel	68.88	0.29	0.54	0.68	33.53	38.59	31.05

# Sonuç ve Değerlendirme

**Başarı Kriterleri:** RandomForestClassifier; %80 doğruluk, 0.20 F1 ve 0.70 ROC AUC barajlarını aynı anda geçen tek model olmuştur.

**Sınıf Dengesizliği Etkisi:** Sadece doğruluğa (Accuracy) odaklanmanın yanıltıcı olduğu; örneğin Emine Güneş'in modelinin yüksek doğruluğa rağmen çok düşük F1 skoruna sahip olmasına kanıtlanmıştır.

**Veri Sızıntısı:** Sızıntı sütunlarının temizlenmesi, modelin gerçek dünya verileriyle çalışabilmesi için kritik bir adım olmuştur.

**Son Söz:** Modelimiz, yüksek boyutlu ve dengesiz bir veri setinde uçuş gecikmelerini ayırt edebilecek kararlı bir performans sergilemiştir.



# Dinlediğiniz İçin Teşekkür Ederiz

Emine Güneş- 22040101036

Mert Oruç-22040101035

Enes İnal-22040101023

Deniz Uğurlu-22040101034

Oğuzhan Özdemir-22040101017